Universidad de Guadalajara
Centro Universitario de Guadalajara



Nombre: Roberto Alejandro Chagra Martínez
Materia: Data Mining y Knowledge Discovery
Actividad: Selección de Base de Datos
Fecha: 15 de Octubre de 2026

Nombre:
Roberto Alejandro Chagra Martinez

Nombre de la base de datos:
Credit Card Fraud Detection Dataset 2026 (Conjunto de datos para la detección de fraude con tarjetas de crédito 2026).

Fuente de donde se obtuvo:
Kaggle mediante el enlace “https://www.kaggle.com/datasets/mohankrishnathalla/credit-card-fraud-detection-dataset-2026/data”.

Breve descripción de la información que contiene:
Este conjunto de datos reúne **100.000 transacciones reales realizadas con tarjeta de crédito durante 2024** e incluye **43 variables** que abarcan información sobre las transacciones, perfiles de clientes, señales de velocidad, indicadores de riesgo, datos de dispositivos y canales, así como el comportamiento de las cuentas. Las distribuciones, tasas de fraude y relaciones entre las señales de riesgo han sido calibradas utilizando como referencia investigaciones publicadas por la **Reserva Federal**, el **Informe Nilson**, **FICO** y el **Banco Central Europeo**.

Número de registros y variables:
100,000 registros y 43 variables.

Problema que les gustaría abordar utilizando esa base de datos.
El descubrimiento de patrones de comportamiento anómalos y reglas de decisión que permitan la detección automatizada de fraude mediante técnicas de Minería de Datos. El enfoque principal será aplicar el proceso completo de *Knowledge Discovery in Databases* (KDD) para extraer conocimiento útil a partir de datos transaccionales en bruto. Esto implicará abordar problemas clásicos de minería como la clasificación y la detección de valores atípicos (*outlier detection*), superando el desafío técnico de identificar señales débiles de fraude dentro de un conjunto de datos masivo y estadísticamente desbalanceado (donde la clase mayoritaria enmascara a la minoritaria).

Justificación de por qué consideran que es adecuada para el proyecto integrador.
Este conjunto de datos proporciona un entorno ideal para aplicar de forma práctica todas las fases metodológicas de la Minería de Datos y el Descubrimiento de Conocimiento:

1. **Desafíos exhaustivos de Preprocesamiento:** Con 43 variables de distinta naturaleza (señales de velocidad, datos de dispositivos, comportamiento de cuenta), la base exigirá aplicar técnicas avanzadas de limpieza, transformación, normalización y reducción de dimensionalidad, etapas que consumen la mayor parte del tiempo en un proyecto real de KDD.

2. **Complejidad para el modelado de Minería de Datos:** Su volumen de 100,000 registros permite la implementación y comparación de múltiples algoritmos de minería (como Árboles de Decisión, Máquinas de Vectores de Soporte, K-Vecinos Más Cercanos o métodos de Ensamble), evaluando cuál es más eficiente para separar las clases en un espacio multidimensional.
3. **Aplicación de técnicas de balanceo:** Dado que las transacciones fraudulentas representan una fracción mínima del total, forzará al equipo a explorar técnicas analíticas de remuestreo (como SMOTE o Tomek Links) para evitar que los algoritmos de minería se sesguen hacia la clase mayoritaria.
4. **Extracción de conocimiento interpretable:** Más allá de la simple predicción, las variables calibradas con datos de instituciones financieras reales permitirán extraer reglas de asociación e identificar qué características específicas (por ejemplo, velocidad de la transacción frente al perfil del cliente) son los principales detonantes del riesgo, generando conocimiento directamente accionable para el negocio.